

Título do Projeto: "Developer Insights BI": Um Panorama do Desenvolvedor de Software Global

Data: 20 de novembro de 2025

Versão: 1.2

1. Objetivo de Negócio

Desenvolver uma solução de **Business Intelligence** robusta e interativa, destinada a estudantes, profissionais de TI, recrutadores e gestores estratégicos. O objetivo é democratizar o acesso aos dados do mercado de tecnologia, permitindo a análise de:

- **Tendências de Carreira:** Evolução salarial (USD), anos de experiência e satisfação no trabalho.
- **Perfil Demográfico:** Distribuição por idade, gênero, deficiência e nível educacional.
- **Geografia do Talento:** Mapeamento global da força de trabalho por país e continente.
- **Modalidades de Trabalho:** Impacto do trabalho remoto, presencial e híbrido nas métricas de satisfação e remuneração.

2. Escopo do Projeto

- **Fonte de Dados:** Dados públicos brutos extraídos da pesquisa anual *Stack Overflow Developer Survey*.
- **Período de Análise:** Consolidação histórica de 15 anos de dados (2011 a 2025), com tratamento de normalização para as mudanças de perguntas e formatos ao longo dos anos.
- **Granularidade:** O grão da tabela fato é definido pela resposta do desenvolvedor associada ao seu papel (Tipo de Desenvolvedor). Se um respondente atua em múltiplos papéis, as métricas são alocadas correspondente a cada atuação.

3. Arquitetura do Modelo de Dados

O Data Mart foi reestruturado para utilizar um **Esquema Estrela (Star Schema)**, otimizado para consultas analíticas rápidas e simplicidade de entendimento.

- Tabela Fato Central (Fato_RespostasDev):
Armazena as métricas quantitativas (Salário Anual, Anos de Experiência, Contagem de Respostas) e as chaves estrangeiras (Surrogate Keys) que ligam o fato ao contexto. A chave primária é composta, garantindo a unicidade do registro com base na combinação das dimensões.
- Dimensões (Contexto):

O modelo conta com 5 dimensões principais, desnormalizadas para otimizar a leitura:

1. **Dim_Tempo (ou Pesquisa):** Controla o ano de referência da pesquisa.
2. **Dim_Geografia:** Hierarquia geográfica normalizada (País → Continente), com tratamento de nomes de países (ISO Standard).
3. **Dim_Perfil:** Dados demográficos do respondente (Idade, Gênero).

4. **Dim_AmbienteTrabalho:** Contexto corporativo (Tamanho da empresa, Status de emprego, Home Office, Satisfação).

5. **Dim_TipoDesenvolvedor:** Categorização profissional (ex: Backend, Frontend, Data Scientist, C-Level).

- Estratégia de Carga (ETL):

Utiliza-se Surrogate Keys (SKs) auto-incrementais para isolar o Data Warehouse das chaves de negócio originais e permitir o gerenciamento eficiente de histórico e performance de joins.

4. Perguntas de Negócio (Business Questions)

O Data Mart foi modelado para responder:

1. **Benchmarking Salarial:** Qual a média salarial (SalarioAnualUSD) comparativa entre países (ex: Brasil vs. EUA) e continentes?
2. **Impacto da Experiência:** Qual a correlação entre anos de experiência profissional (AnosDeExperienciaProfissional) e a remuneração, segmentada por nível de senioridade?
3. **Ambiente Corporativo:** Existe correlação direta entre a modalidade de trabalho (Remoto/Híbrido/Presencial) e o índice de satisfação do colaborador (SatisfacaoTrabalho)?
4. **Perfil Demográfico:** Como a idade e o gênero influenciam a distribuição nos diferentes tipos de cargos de desenvolvimento (ex: C-Level vs. DevOps)?
5. **Tecnologias (Roadmap):** *[Previsto]* Quais as linguagens e plataformas de nuvem mais utilizadas atualmente versus as mais desejadas para o futuro?

5. Indicadores de Desempenho (KPIs)

- **Média Salarial Global (USD):** Valor normalizado anual (ConvertedCompYearly).
- **Senioridade Média:** Média de anos de codificação e anos de experiência profissional.
- **Satisfação Média:** Score qualitativo normalizado sobre a satisfação com o emprego atual.

6. Modelagem Dimensional (Esquema Estrela)

Para lidar com a complexidade e volume do arquivo CSV de origem, adotou-se o **Star Schema**, simplificando os joins e otimizando a performance de leitura no Power BI.

Tabela Fato: Fato_RespostasDev

Centraliza as métricas e conecta as dimensões. Sua chave primária é composta para garantir a unicidade do registro.

- **Chaves (FKs):**
 - SK_Geografia
 - SK_Perfil
 - SK_AmbienteTrabalho

- SK_TipoDev
- SK_Pesquisa (Dimensão de Tempo)
- **Métricas:**
 - SalarioAnualUSD (Decimal)
 - AnosDeExperienciaCodigo (Inteiro)
 - AnosDeExperienciaProfissional (Inteiro)
 - QtdRespostas (Inteiro - Default 1)

Dimensões (Perspectivas de Análise)

1. Dim_Geografia

- *Atributos:* País (Padronizado ISO), Região, Continente.
- *Objetivo:* Análise espacial e comparação econômica regional.

2. Dim_Perfil

- *Atributos:* Idade, Gênero, Deficiência, Nível de Escolaridade (*EdLevel* mapeado aqui ou em dimensão própria).
- *Objetivo:* Análise de diversidade e perfil demográfico.

3. Dim_AmbienteTrabalho

- *Atributos:* Tamanho da Empresa (*OrgSize*), Status de Emprego, Modalidade (Remoto/Presencial), Satisfação.
- *Objetivo:* Entender a cultura organizacional e modelos de contratação.

4. Dim_TipoDesenvolvedor

- *Atributos:* Descrição do cargo (Backend, Frontend, Fullstack, Data Scientist, etc.).
- *Nota:* Permite analisar salários específicos por especialidade.

5. Dim_Pesquisa (Tempo)

- *Atributos:* Ano da Pesquisa.
- *Objetivo:* Permitir a análise de evolução temporal (Time Intelligence).

Principais Desafios de ETL (Pentaho) Resolvidos:

1. **Tratamento de Nulos:** Campos obrigatórios como StatusEmprego receberam tratamento padrão ("Não Informado") para evitar violação de integridade no banco.
2. **Normalização Geográfica:** Uso de *Value Mapper* externo para converter variações de nomes de países e códigos ISO.
3. **Flattening de Dados:** Transformação de colunas multivaloradas (ex: Tipos de Dev separados por ;) em múltiplas linhas na tabela fato para correta contagem e agregação.

4. Estrutura Detalhada das Tabelas

4.1. Tabela Fato: Fato_RespostasDev

Esta tabela centraliza as métricas quantitativas de cada resposta da pesquisa.

Nome da Coluna	Tipo de Chave	Descrição
SK_Geografia	PK, FK	Chave da dimensão de Geografia.
SK_Perfil	PK, FK	Chave da dimensão de Perfil.
SK_Educacao	PK, FK	Chave da dimensão de Educação.
SK_AmbienteTrabalho	PK, FK	Chave da dimensão de Ambiente de Trabalho.
SK_Pesquisa	PK, FK	Chave da dimensão de Pesquisa (ano).
ID_Respondente	Chave Degenerada	ID original do respondente no arquivo da pesquisa.
SalarioAnualUSD	Métrica	Salário anual, normalizado para dólares americanos.
AnosDeExperienciaCodigo	Métrica	Anos totais de experiência com programação.
AnosDeExperienciaProfissional	Métrica	Anos de experiência profissional com programação.

4.2. Tabelas de Dimensão

Estas tabelas contêm os atributos descritivos e qualitativos para a análise.

- **Dim_Geografia:** Armazena a localização geográfica do respondente (País, Região, Continente).
- **Dim_Perfil:** Contém dados demográficos como Faixa Etária, Gênero e Orientação Sexual (quando disponível).
- **Dim_Educacao:** Descreve o histórico educacional, como Nível Formal de Educação e Área de Estudo.
- **Dim_AmbienteTrabalho:** Informações sobre o contexto profissional, incluindo Status de Emprego, Tamanho da Empresa e Modalidade de Trabalho.
- **Dim_Pesquisa:** Dimensão essencial que contextualiza a pesquisa no tempo (Ano, Nome da Pesquisa).
- **Dim_Tecnologia:** Catálogo único de todas as tecnologias (linguagens, bancos de dados, plataformas, etc.).
- **Dim_TipoDesenvolvedor:** Catálogo único dos diferentes papéis e especialidades dos desenvolvedores.

4.3. Tabelas Ponte (Bridge Tables)

Essas tabelas são cruciais para modelar corretamente os relacionamentos de "muitos-para-muitos".

- **Bridge_RespostaTipoDev:** Conecta uma única resposta na tabela fato a múltiplos papéis na Dim_TipoDesenvolvedor, já que um profissional pode se identificar com mais de uma especialidade (ex: Back-end e DevOps).

- **Estrutura:** Contém a chave primária composta da tabela fato e a chave do tipo de desenvolvedor (SK_TipoDev). Não possui atributos adicionais, pois a relação é uma afirmação direta.